

Analisa Performa Penjualan Restoran dengan Konsep Data Engineering

Menggunakan Pentaho, MySQL, dan Apache Airflow

Julius Gilang Nugroho	Hansel Lie Arifin	Joshua Ferdinand	Sylvester Luigi	Vinson Mervin
Data Engineering	Data Engineering	Data Engineering	Hidayat	Data Engineering
Binus@Alam Sutera	Binus@Alam Sutera	Binus@Alam Sutera	Data Engineering	Binus@Alam Sutera
Tangerang, Indonesia	Tangerang, Indonesia	Tangerang, Indonesia	Binus@Alam Sutera	Tangerang, Indonesia
julius.nugroho@binus.ac.id	hansel.arifin@binus.ac.id	joshua.ferdinand@binus.ac.id	Tangerang, Indonesia	vinson.mervin@binus.ac.id
		sylvester.hidayat@binus.ac.id		

Abstract— Laporan ini menyajikan implementasi pipeline data engineering end-to-end yang diterapkan pada dataset penjualan restoran dari Kaggle. Dataset yang dipublikasikan oleh Ahmed Mohamed tersebut berisi catatan transaksi restoran yang memiliki berbagai permasalahan kualitas data, seperti keberadaan nilai kosong (missing values), duplikasi, dan format yang tidak konsisten. Pipeline yang dibangun mencakup seluruh tahapan Data Engineering Lifecycle, meliputi data ingestion, pembersihan, transformasi, pemodelan star schema, validasi kualitas, otomatisasi menggunakan Pentaho Jobs dan Apache Airflow, serta penyajian data melalui dashboard Power BI. Hasil implementasi menunjukkan bahwa pipeline yang terstruktur mampu mengubah data mentah menjadi insight analitik bisnis yang andal dan informatif.

Keywords— data engineering, ELT, Pentaho Data Integration, Apache Airflow, PostgreSQL, star schema, penjualan restoran, pembersihan data, Power BI

I. PENDAHULUAN

Proyek ini mengimplementasikan pipeline data engineering menggunakan dataset “Restaurant Sales – Dirty Data for Cleaning Training” yang bersumber dari Kaggle. Dataset ini memuat lebih dari 15.000 catatan transaksi restoran selama periode tahun 2022 hingga 2023. Kondisi data mentah (raw data) tersebut memiliki banyak permasalahan, mulai dari tingginya jumlah missing value, keberadaan data ganda (duplicate data), hingga ketidakkonsistenan tipe data yang tidak sesuai dengan isi kolomnya. Oleh karena itu, proses pembersihan data (data cleaning) mutlak diperlukan agar tahapan analisis data dapat menghasilkan insight yang akurat.

Dataset ini terdiri dari sembilan kolom utama, yaitu Order ID, Customer ID, Category, Item, Price, Quantity, Order Total, Order Date, dan Payment Method. Pada kolom Kategori, terdapat lima jenis kategori menu (Main Dishes, Starters,

Desserts, Side Dishes, dan Drinks) yang mencakup total 20 item menu. Data ini juga merekam aktivitas pemesanan dari 100 pelanggan unik secara berkelanjutan. Selain itu, terdapat tiga jenis metode pembayaran yang digunakan dalam transaksi, yaitu Cash, Credit Card, dan Digital Wallet.

Tujuan proyek ini adalah:

- (1) Merancang pipeline data yang komprehensif dan terstruktur.
- (2) Menerapkan konsep ELT (Extract, Load, Transform) menggunakan Pentaho Data Integration.
- (3) Memastikan kualitas serta keandalan data yang diproses.
- (4) Mengotomatisasi alur kerja ELT.
- (5) Menyajikan data yang telah diolah ke dalam bentuk dashboard analitik di Power BI.

II. METODOLOGI

A. Sumber Data

Dataset yang digunakan merupakan data transaksi pemesanan restoran berformat CSV yang diperoleh dari platform Kaggle. Setelah melalui serangkaian proses pembersihan, dataset ini menghasilkan 15.252 baris data transaksi yang bersih.

Kolom	Tipe Data	Deskripsi
Order ID	VARCHAR	Identitas unik transaksi
Customer ID	VARCHAR	Identitas unik pelanggan
Category	VARCHAR	Kategori menu

Item	VARCHAR	Nama item yang dipesan
Price	INTEGER	Harga satuan item
Quantity	INTEGER	Jumlah item dipesan
Order Total	INTEGER	Total nilai transaksi
Order Date	DATETIME	Tanggal transaksi
Payment Method	VARCHAR	Metode pembayaran

B. Data Ingestion

Proses pengambilan data dilakukan menggunakan Pentaho Data Integration (PDI) dengan menerapkan strategi full load. Data dari file CSV diekstrak dan dimuat ke dalam tabel staging pada basis data MySQL melalui skrip transformasi Cleaning_Transformation.ktr.

C. Penyimpanan Data

Arsitektur penyimpanan data dibagi menjadi dua lapisan utama, yaitu OLTP dan OLAP. Lapisan OLTP berfungsi sebagai area pendaratan di mana data mentah disimpan dalam tabel staging MySQL tanpa modifikasi sebagai cadangan referensi. Sementara itu, lapisan OLAP merupakan data warehouse star schema yang memuat data hasil transformasi ke dalam struktur Dimension Table dan Fact Table. MySQL dipilih sebagai infrastruktur basis data karena kapabilitasnya dalam menangani query analitik serta kemudahannya integrasinya dengan platform Pentaho.

D. Transformasi Data

Transformasi data dieksekusi melalui serangkaian file transformasi Pentaho. Tahapan ini terbagi menjadi dua proses utama yaitu pembersihan raw data yang masih mengandung banyak error agar siap dianalisis, serta pembentukan Dimension Table menggunakan logika Slowly Changing Dimension (SCD) Tipe 1 dan Tipe 0.

- **Pembersihan Data (Cleaning_Transformation.ktr):** Langkah-langkah pembersihan meliputi konversi tipe data pada kolom numerik, penghapusan karakter titik yang tidak valid pada kolom Price, Quantity, dan Order Total, serta identifikasi dan penghapusan baris bernilai null pada kolom Item maupun Payment Method. Duplikasi data pada kolom Order ID juga dihapus dalam tahapan ini. Serangkaian proses ini berhasil mengurangi volume dari 17.500 data kotor menjadi sekitar 15.000 baris data bersih. Data bersih tersebut kemudian diekspor ke dalam format CSV dan diimpor kembali ke penyimpanan OLTP MySQL. Setelah itu baru mulai dari sini, seluruh proses analisis tidak lagi bergantung pada raw data Kaggle, melainkan sepenuhnya menggunakan data yang telah dibersihkan.

- **Transformasi Dimensi:** Setelah data bersih dipersiapkan, tahap selanjutnya adalah mengekstraksi dan membangun dimension table serta fact table.

File KTR	Output	Deskripsi
customer_transformation.ktr	customerdim	Pelanggan unik
item_transformation.ktr	itemdim	Item menu unik
payment_transformation.ktr	paymentdim	Metode pembayaran
time_transformation.ktr	timedim	Dimensi waktu dari Order Date
fact_transformation.ktr	salesfact	Tabel fakta transaksi lengkap

Seluruh proses ini dikonfigurasi di dalam Pentaho Spoon. Implementasi SCD Tipe 1 memanfaatkan tools Table input, Unique rows (HashSet), dan Insert/Update. Di sisi lain, SCD Tipe 0 menggunakan Table input, Unique rows (HashSet), dan Table output. Pendekatan SCD Tipe 0 diterapkan secara spesifik untuk memuat tabel timedim dan salesfact, sedangkan tabel dimensi lainnya menggunakan pendekatan SCD Tipe 1.

E. Pemodelan Data

Model data dirancang dengan pendekatan Star Schema yang memisahkan data transaksi utama (fact table) dari atribut deskriptifnya (dimension table). Tabel fakta salesfact bertugas menyimpan seluruh catatan transaksi beserta foreign key yang merujuk ke setiap dimensi, didampingi metrik kuantitatif seperti Price, Quantity, Order ID, dan Order Total. Empat tabel dimensi yang mengelilinginya meliputi customerdim, itemdim, paymentdim, dan timedim. Desain skema ini terbukti sangat optimal untuk divisualisasikan, sekaligus mendukung performa query analitik yang responsif dan efisien.

F. Kualitas Data dan Validasi

Pemeriksaan kualitas data dilakukan secara ketat setelah proses transformasi selesai. Aturan validasi yang diterapkan dirangkum pada Tabel dibawah.

Pemeriksaan	Implementasi	Tujuan
Duplikasi Order ID	Remove Order ID duplicate	Keunikan Transaksi
Null pada Item	Remove Null Item	Kelengkapan data item

Null pada Payment Method	remove Null Payment Method	Kelengkapan data payment method
Format tipe data	Change data type	Konsistensi numerik data
Karakter tidak valid	Remove (.) in numeric	Membersihkan input kotor sehingga bisa dilakukan analisa serta bisa diubah menjadi tipe data integer
Duplikasi data	Unique rows (HashSet)	Cegah duplikasi dimensi

G. Otomasi dan Orkestrasi

Otomatisasi alur pipeline diterapkan pada dua level yang berbeda:

1. Pentaho Job (Job1.kjb): Menjalankan seluruh file transformasi secara berurutan dengan alur: Start → Cleaning → customer → item → payment → time → fact.
2. Apache Airflow: Dipakai sebagai orkestrator penjadwalan tingkat lanjut (advanced scheduling) menggunakan DAG yang dinamakan test_DAG. DAG ini dikonfigurasi untuk tereksekusi setiap hari menggunakan parameter @daily. Pengujian manual mencatatkan status eksekusi Success dalam waktu respons yang sangat singkat, yaitu 4 detik, di mana serangkaian tugas pada task run_job sukses diselesaikan.

III. HASIL VISUALISASI

A. Hasil Transformasi dan Pemodelan

Secara keseluruhan, pipeline ELT berhasil tereksekusi dengan sempurna untuk merekayasa struktur data warehouse star schema. Proses ini mengolah secara efektif 15.252 baris transaksi bersih dari raw data..

Tabel	Jenis	Record
fact_orders	Fact Table	15.252 baris
dim_customer	Dimension	~100 pelanggan unik
dim_item	Dimension	20 item menu
dim_payment	Dimension	3 metode pembayaran
dim_time	Dimension	Rentang 2022–2023

B. Hasil Orkestrasi Airflow


Pengujian yang dilakukan terhadap DAG Airflow secara manual berjalan tanpa kegagalan. Log eksekusi (run notes) menunjukkan Status success, yang dipicu melalui run manual, dengan total waktu eksekusi (run duration) 00:00:04. Task run_job berhasil dieksekusi berdasarkan pengaturan jadwal otomatis @daily pada pukul 00:00:00 UTC.

C. Hasil Visualisasi

Data bersih yang telah diproses kemudian disajikan secara interaktif menggunakan Power BI yang dibagi menjadi tiga halaman dashboard utama.




Halaman Pertama Menampilkan Indikator Kinerja Utama (KPI) yang mencatatkan Total Revenue sebesar 305K, Total Orders sebanyak 15K, Average Order Value senilai 19,98, Total Quantity sebesar 46K, serta rasio AVG Quantity/Order sebesar 3,02. Distribusi demografi penggunaan metode pembayaran terpantau sangat seimbang dan merata: Cash (33,38%), Credit Card (33,37%), dan Digital Wallet (33,24%). Sementara itu, analisis tren pendapatan (revenue) bulanan menyoroti bahwa puncak perolehan tertinggi (peak revenue) di tahun 2022 terjadi pada periode Maret-April. Sebaliknya, performa pesanan dan revenue secara umum di tahun 2023 terpantau mengalami perlambatan dibandingkan rekor pencapaian di tahun sebelumnya. Halaman ini juga memvisualisasikan matriks distribusi kategori menu terfavorit per tahun berdasarkan ragam pembayaran yang dipilih.



Halaman Kedua Menunjukkan wawasan komparatif kinerja setiap produk menu. Grilled Chicken ditunjukkan sebagai item

pencetak revenue tertinggi yang kemudian diikuti secara agregat oleh Pasta Alfredo dan Steak. Secara keseluruhan, klasifikasi menu makanan berat (Main Dishes) memuncaki revenue sekaligus mengungguli kategori lainnya dengan margin kontribusi perolehan omset yang paling masif. Namun, terdapat suatu anomali temuan menarik terkait pasar, di mana jumlah order kuantitas absolut tampak nyaris seragam (uniform distribution) berada pada ekuator kisaran angka 9.000 pesanan per seluruh jenis kelompok kategori menu.



Halaman Ketiga Menunjukkan wawasan konsumen dengan menampilkan Pelanggan bernama CUST_093 sebagai pimpinan puncak Top Spender berlandaskan akumulasi total revenue. Kalkulasi tabulasi volume order per harinya merefleksikan frekuensi transaksi yang stabil tanpa adanya ketimpangan tajam antara hari operasional (weekdays) dan masa akhir pekan (weekends). Rasio pertumbuhan total pemesanan bulanan juga cenderung berfluktuasi secara konsisten di antara ambang batas 1.150 hingga 1.350 order, yang memvalidasi bahwa fundamental kelangsungan bisnis berjalan secara sangat ideal, tanpa mengalami lonjakan fluktuatif (anomali) yang berarti.

IV. PEMBAHASAN

Infrastruktur arsitektur pipeline ELT pada proyek ini menunjukkan bahwa implementasi kerangka kerja data engineering yang terstruktur dan masif dapat membuat deretan transaksi raw data yang kotor, bertransformasi ke dalam sebuah insight bisnis yang bermanfaat.

Terdapat beberapa instrumen analisis pokok (key findings) yang patut dicermati:

- 1. Diversitas tipe alat bayar di portfolio meratanya adalah peringatan krusial yang menegaskan esensi dan krusialitas salahan dan penopangan operasional seluruh ekosistem saluran infrastruktur fasilitas perbankan dan transaksi digital restoran.
- 2. Penguasaan pangsa pasar absolut dari golongan makanan pokok (Main Dishes) layak dikapitalisasi lebih progresif untuk mendongkrak margin keuntungan melalui promosi atau optimalisasi resep inventaris menu.

3. Garis konsistensi konstan yang dibuktikan dari nilai volume pemesanan konsumen antar bulanan menandakan bahwa fondasi mutu kelangsungan performa operasional restoran sudah berjalan di jalan yang prima dan berdaya saing baik.

Evaluasi kapabilitas komponen alat teknis terangkum secara spesifik di dalam Tabel.

Komponen	Teknologi	Keunggulan	Keterbatasan
ELT Tool	Pentaho Spoon	Antarmuka visual yang terintegrasi, sangat mempermudah interaksi dan ramah guna, dilengkapi koneksi multi-basis data.	Fleksibilitas konfigurasinya terkadang menjadi residu penanganan bila dihadapkan pada perumusan variabel logika algoritma rumit
Database	MySQL	Teruji perihwal efisiensi andalnya, ditunjang status perangkat sumber bebas (<i>open-source</i>), dan <i>query engine</i> cepat.	Kapasitas agregasinya seringkali perlu penalaan (<i>tuning</i>) serta perombakan masif untuk mengakomodir lonjakan beban eksekusi beban masif (<i>large-scale data</i>).
Orkestrasi	Apache Airflow & Pentaho Carte	Kemampuan merumuskan dan mengeksekusi fleksibilitas skenario penjadwalan	Rangkaian arsitektur prasyarat instalasi serta penyiapannya sangat membingungkan

		(<i>scheduling flexibility</i>) disertai modul pemantauan analitik (<i>log monitoring</i>) instan.	n (<i>complex setup</i>).
Visualisasi	Power BI	Tampilan GUI visual menawan, disajikan sangat estetik dan interaktif bagi <i>end-user</i> .	Akses operasional peranti lunaknya tunduk secara limitatif oleh kepemilikan lisensi eksklusif terikat dari produsen pabrikan Microsoft.
Data Model	Star Schema	Performa penelusuran agregasi yang mumpuni dengan tingkat <i>query</i> berkinerja tinggi serta skemanya intuitif komprehensif .	Parameter skemanya beroperasi kurang proporsional bilamana menangani klasifikasi klaster muatan varietas wujud struktur <i>data tidak</i>

			<i>terstruktur (unstructured data)</i> .
--	--	--	--

V. KESIMPULAN

Seluruh proyek perancangan arsitektur pipeline data engineering end-to-end ini menunjukkan implementasi menyeluruh dari tahapan Data Engineering Lifecycle. Proses dimulai dari pengolahan data mentah berbentuk file CSV yang masih mengandung dirty data, kemudian dilakukan proses pembersihan, transformasi, dan modifikasi data menggunakan Pentaho Data Integration (PDI). Setelah itu, data disusun ke dalam struktur data warehouse berbasis star schema pada database MySQL, dilanjutkan dengan otomatisasi dan orkestrasi proses menggunakan Apache Airflow, hingga akhirnya disajikan dalam bentuk dashboard interaktif melalui Microsoft Power BI.

Seluruh pipeline berhasil berjalan secara online dan terintegrasi dengan baik antar tools yang digunakan. Keberhasilan sistem dibuktikan melalui eksekusi DAG pada Apache Airflow yang mampu menyelesaikan proses orkestrasi otomatis dengan status Success dalam durasi sekitar 4 detik. Hasil ini menunjukkan efisiensi, keandalan, dan ketersediaan pipeline dalam mendukung proses data secara berkelanjutan. Pada tahap akhir, dashboard Power BI menyajikan berbagai insight penting, seperti identifikasi produk terlaris, pola penggunaan metode pembayaran pelanggan, hingga tren penjualan harian dan bulanan restoran. Secara keseluruhan, proyek ini menunjukkan bahwa arsitektur data engineering yang terintegrasi merupakan fondasi penting dalam mendukung ekosistem analitik modern secara efektif dan berkelanjutan

VI. LAMPIRAN




Image 1. Cleaning Transformation




Image 2. Customer Dimension Transformation

Spoon - item_transformation

File Edit View Action Tools Help

View Design

Search

Configurations

- Database connections
- Kettle cluster schemas
- Partition schemas
- Run configurations
- Slave server
- VFS Connections

Execution Results

Logging Execution History Step Metrics Performance Graph Metrics Preview data

First rows Last rows Off

#	Category	Item
1	Side Dishes	Side Salad
2	Side Dishes	Mashed Potatoes
3	Main Dishes	Grilled Chicken
4	Main Dishes	Pasta Alfredo
5	Main Dishes	Salmon
6	Side Dishes	Garlic Bread
7	Desserts	Brownie
8	Starters	Sweet Potato Fries
9	Drinks	Lemonade
10	Main Dishes	Vegetarian Platter

Image 3. Item Dimension Transformation

Spoon - payment_transformation

File Edit View Action Tools Help

View Design

Search

Configurations

- Database connections
- Kettle cluster schemas
- Partition schemas
- Run configurations
- Slave server
- VFS Connections

Execution Results

Logging Execution History Step Metrics Performance Graph Metrics Preview data

First rows Last rows Off

#	Payment Method
1	Credit Card
2	Digital Wallet
3	Cash

Image 4. Payment Dimension Transformation

Spoon - time_transformation

File Edit View Action Tools Help

Connect

View Design

Search

Configurations

- Database connections
- Kettle cluster schemas
- Partition schemas
- Run configurations
- Slave server
- VFS Connections

Table input → Unique rows (HashSet) → Table output

Execution Results

Logging Execution History Step Metrics Performance Graph Metrics Preview data

First rows Last rows Off

#	full_date	day	week	month	quarter	year	dayname	monthname
1	2023/12/21 00:00:00.000000000	21	51	12	4	2023	Thursday	December
2	2023/05/19 00:00:00.000000000	19	20	5	2	2023	Friday	May
3	2023/09/27 00:00:00.000000000	27	39	9	3	2023	Wednesday	September
4	2022/05/15 00:00:00.000000000	15	20	5	2	2022	Sunday	May
5	2022/07/20 00:00:00.000000000	20	29	7	3	2022	Wednesday	July
6	2022/08/19 00:00:00.000000000	19	33	8	3	2022	Friday	August
7	2023/12/09 00:00:00.000000000	9	49	12	4	2023	Saturday	December
8	2023/10/30 00:00:00.000000000	30	44	10	4	2023	Monday	October
9	2023/04/11 00:00:00.000000000	11	15	4	2	2023	Tuesday	April
1.	2023/08/18 00:00:00.000000000	18	33	8	3	2023	Friday	August

Image 5. Time Dimension Transformation

Spoon - fact_transformation

File Edit View Action Tools Help

Connect

View Design

Search

Configurations

- Database connections
- Kettle cluster schemas
- Partition schemas
- Run configurations
- Slave server
- VFS Connections

Table input → Unique rows (HashSet) → Table output

Execution Results

Logging Execution History Step Metrics Performance Graph Metrics Preview data

First rows Last rows Off

#	customer_code	item_code	payment_code	time_code	order id	Price	Quantity	Order Total	Order Date
1	1	1	1	1	ORD_705844	3	1	3	2023/12/21 00:00:00.000000000
2	1	1	1	1	731 ORD_705844	3	1	3	2023/12/21 00:00:00.000000000
3	2	2	2	2	ORD_338528	4	3	12	2023/05/19 00:00:00.000000000
4	2	2	2	2	732 ORD_338528	4	3	12	2023/05/19 00:00:00.000000000
5	3	3	1	3	ORD_443849	15	4	60	2023/09/27 00:00:00.000000000
6	3	3	1	3	733 ORD_443849	15	4	60	2023/09/27 00:00:00.000000000
7	4	4	3	4	ORD_648269	12	4	48	2022/05/15 00:00:00.000000000
8	4	4	3	3	734 ORD_648269	12	4	48	2022/05/15 00:00:00.000000000
9	4	5	2	5	ORD_381680	18	5	90	2022/07/20 00:00:00.000000000
1.	4	5	2	2	735 ORD_381680	18	5	90	2022/07/20 00:00:00.000000000

Image 6. Fact table SalesFact Transformation




Image 7. Job Automation & Orchestration




Image 8. DAG Automation & Orchestration Success Run

```
Ubuntu-24.04 > home > julius > airflow > dags > test_DAG.py
1  from airflow import DAG
2  from airflow.providers.http.operators.http import HttpOperator
3  import datetime
4
5  FILENAME = "C:\semester 4\data eng\lab\Job1.kjb"
6
7  with DAG(
8      dag_id = "test_DAG",
9      start_date=datetime.datetime(2026, 5, 27),
10     schedule_interval="@daily",
11     catchup=False
12 ) as dag:
13     run_job=HttpOperator(
14         task_id="run_job",
15         http_conn_id="carte_conn",
16         endpoint="kettle/executeJob",
17         data={
18             'job': FILENAME
19         },
20         method="GET"
21     )
```

Image 9. Automation & Orchestration for DAG code